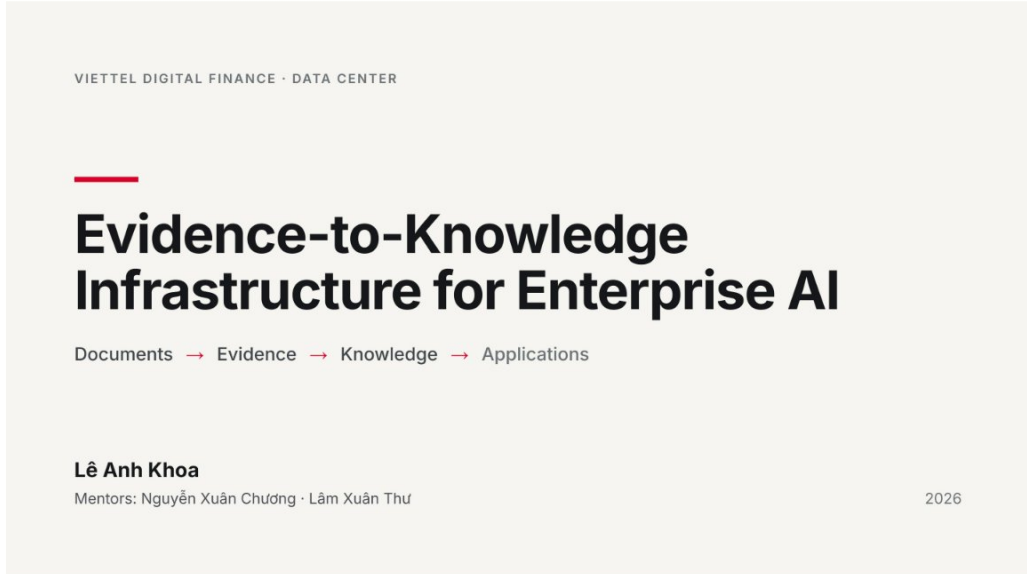
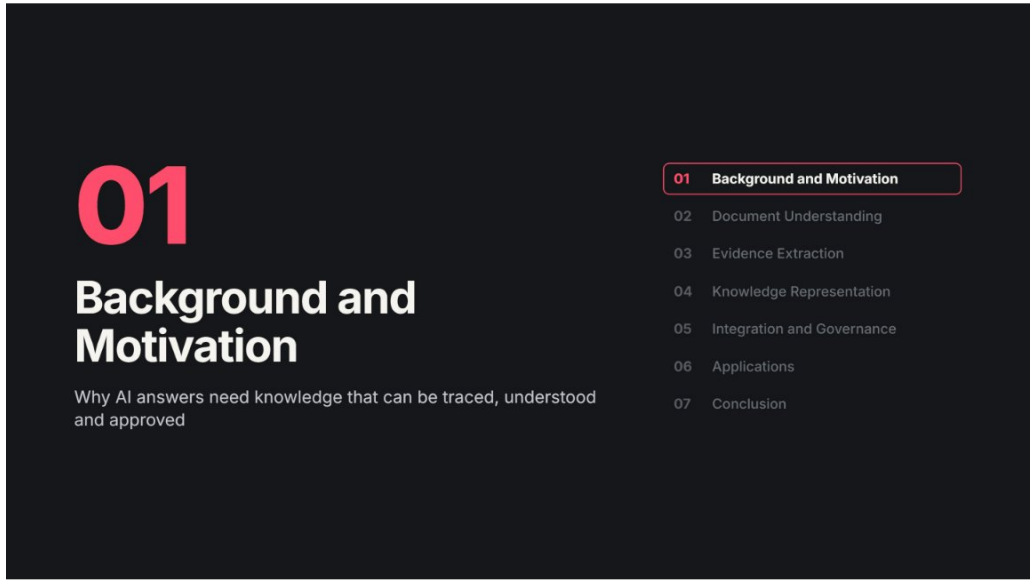
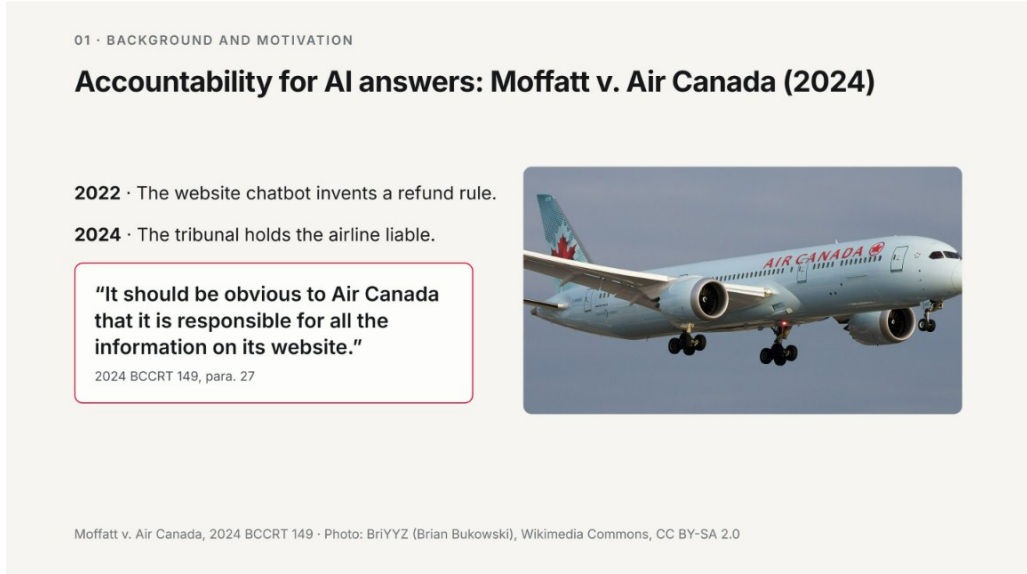


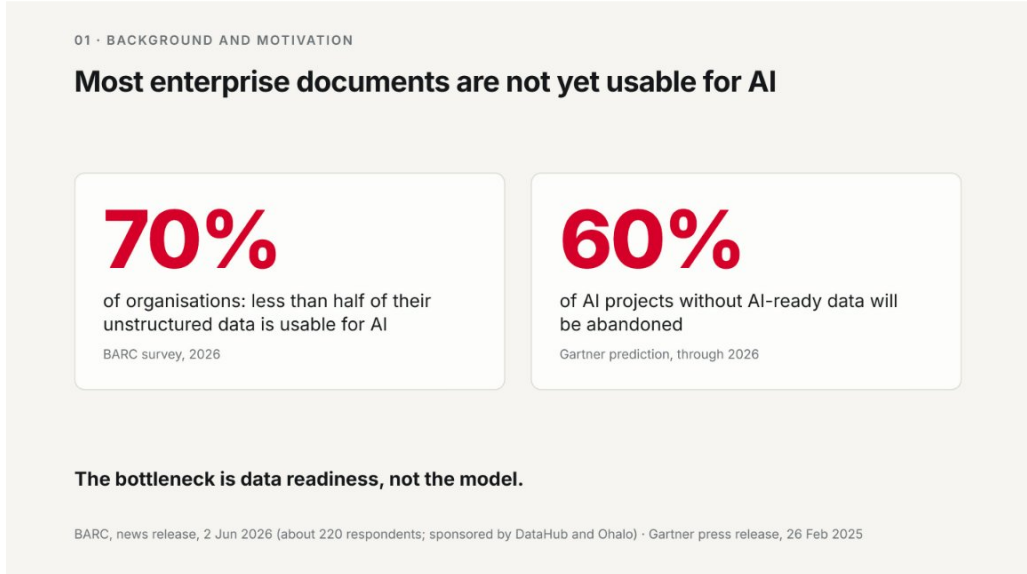
Xin chào hội đồng. Em là Lê Anh Khoa. Đề tài của em là hạ tầng đi từ tài liệu đến tri thức cho AI doanh nghiệp: biến tài liệu thành bằng chứng có địa chỉ nguồn, rồi thành tri thức có ngữ nghĩa, được duyệt và có phiên bản, để các ứng dụng AI dùng lại.



Phần 1: bối cảnh và động lực. Vì sao câu trả lời của AI trong doanh nghiệp cần tri thức truy được nguồn, rõ nghĩa và đã được duyệt.



Năm 2022, chatbot của Air Canada tự đưa ra một quy định hoàn tiền không có trong chính sách. Hãng lập luận chatbot tự chịu trách nhiệm. Năm 2024, tòa bác lập luận đó và buộc hãng bồi thường: doanh nghiệp chịu trách nhiệm về mọi thông tin trên website của mình. Bài học: câu trả lời của AI phải khớp với nguồn có thẩm quyền của chính tổ chức.



Hai nguồn độc lập. BARC 2026: 70% tổ chức nói chưa tới một nửa dữ liệu phi cấu trúc của họ dùng được cho AI; 35% còn không truy được dữ liệu đó được dùng ở đâu. Gartner dự báo đến hết 2026, 60% dự án AI thiếu dữ liệu sẵn sàng sẽ bị bỏ. Điểm nghẽn là dữ liệu, không phải mô hình.

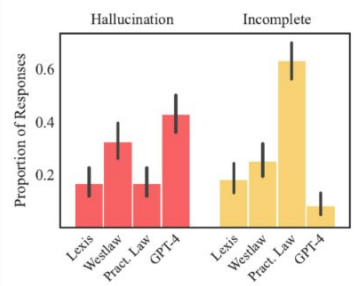
01 · BACKGROUND AND MOTIVATION

A citation is not yet evidence

Commercial legal tools built on retrieval (RAG), marketed as "hallucination-free":

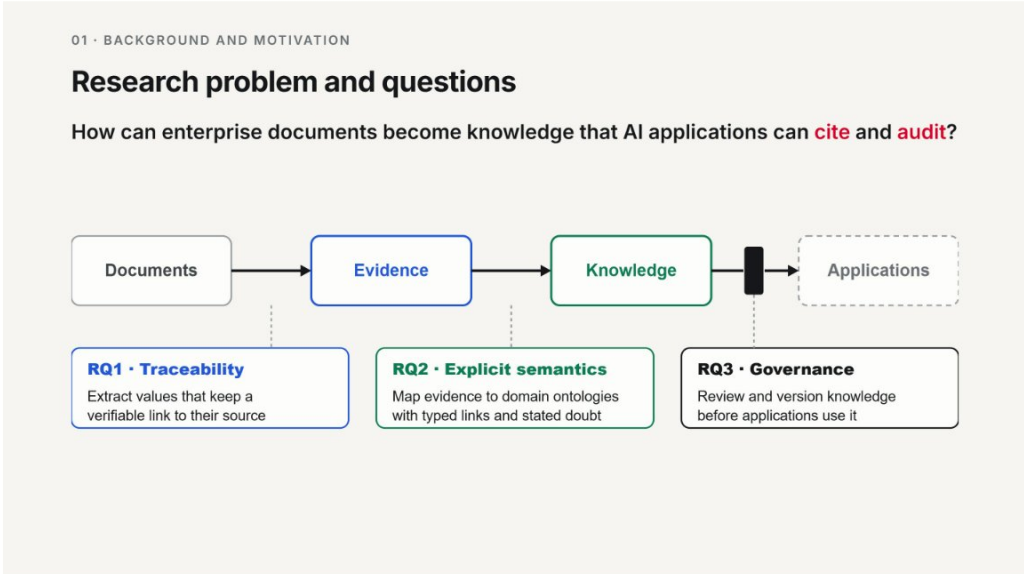
17–33%

of answers hallucinated, including answers that **cite a source that does not support them**

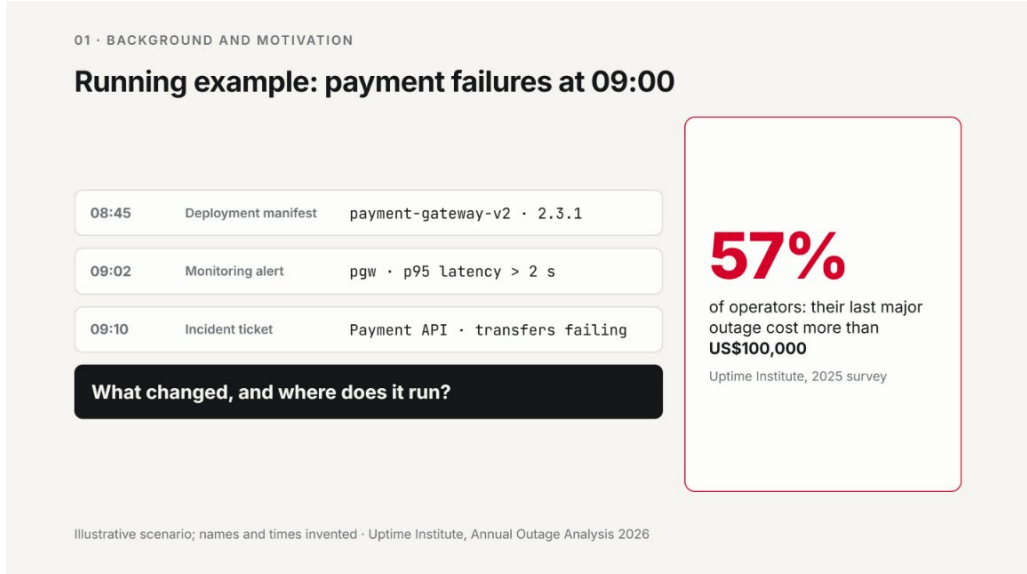


Magesh et al., "Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools", Stanford RegLab and HAI, arXiv:2405.20362

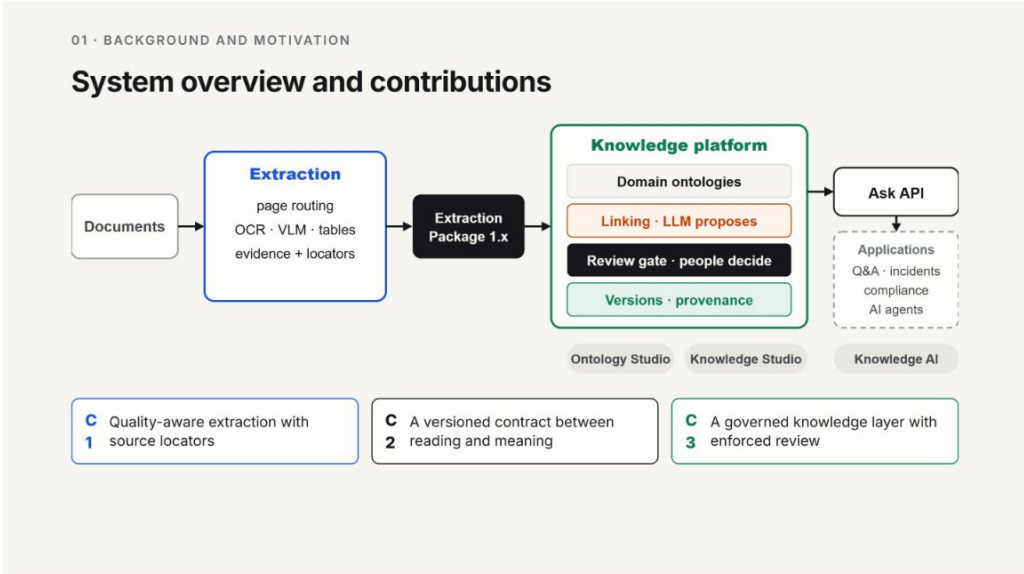
RAG là hướng đúng, nhưng chưa đủ. Nghiên cứu đăng ký trước của Stanford trên các công cụ pháp lý thương mại, vốn được quảng cáo là không bịa: 17 đến 33% câu trả lời vẫn bịa. Định nghĩa của họ gồm cả câu trả lời có trích dẫn nhưng nguồn được trích không ủng hộ nó. Nghĩa là trích dẫn chưa phải bằng chứng: cần biết giá trị đến từ đúng chỗ nào, nghĩa là gì, và ai đã xác nhận.



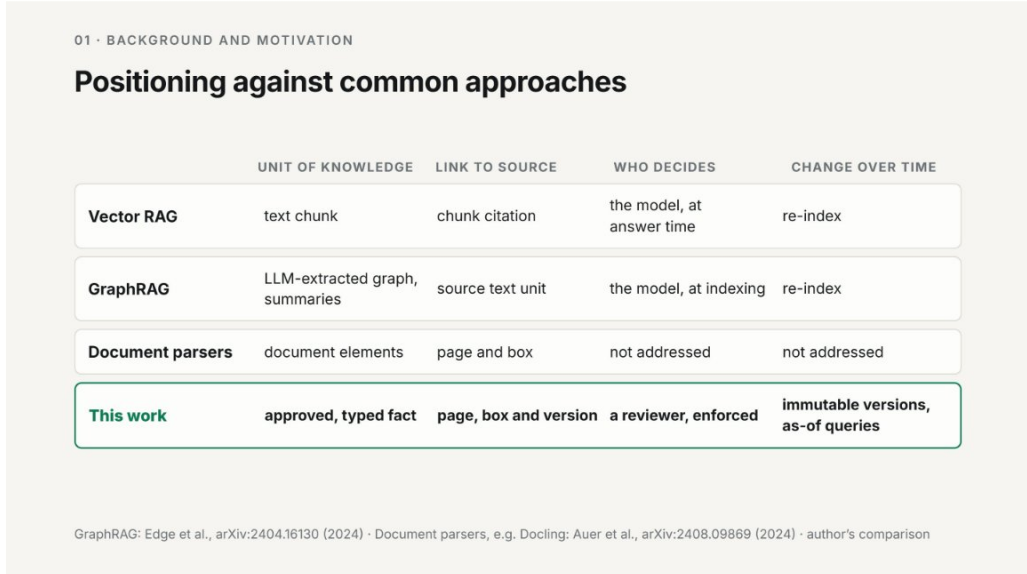
Câu hỏi chung: làm sao để tài liệu doanh nghiệp trở thành tri thức mà ứng dụng AI dẫn nguồn và kiểm toán được. Ba câu hỏi nghiên cứu nằm trên ba chặng. RQ1: trích xuất giá trị mà vẫn giữ liên kết kiểm chứng được tới nguồn. RQ2: ánh xạ bằng chứng vào ontology của miền với liên kết có kiểu và ghi rõ chỗ chưa chắc. RQ3: duyệt và đánh phiên bản tri thức trước khi ứng dụng dùng; cái cổng màu đen trên sơ đồ là bước duyệt đó.



Ví dụ xuyên suốt bài: 9 giờ sáng, giao dịch chuyển tiền lỗi hàng loạt. Ba nguồn nói về cùng một dịch vụ bằng ba tên: manifest ghi payment-gateway-v2, cảnh báo ghi pgw, ticket ghi Payment API. Câu hỏi của người vận hành: cái gì vừa thay đổi, và nó chạy ở đâu. Trả lời được câu này cần cả ba thứ: bằng chứng có nguồn, nghĩa rõ ràng, và tri thức đã duyệt theo thời gian. Theo Uptime Institute, 57% đơn vị cho biết sự cố lớn gần nhất tốn hơn 100 nghìn đô.



Toàn cảnh hệ thống em đã xây. Tài liệu đi qua phân hệ trích xuất: định tuyến theo trang, OCR hoặc mô hình thị giác ngôn ngữ, nhận dạng bảng, và ra bằng chứng có địa chỉ nguồn. Đầu ra là gói ExtractionPackage có phiên bản. Nền tảng tri thức gồm ontology theo miền, bước liên kết do LLM đề xuất, cổng duyệt do người quyết định, và kho phiên bản có nguồn gốc. Ứng dụng lấy tri thức qua Ask API. Ba công cụ giao diện: Ontology Studio, Knowledge Studio, Knowledge AI. Đóng góp: trích xuất có địa chỉ nguồn, hợp đồng dữ liệu tách đọc khỏi hiểu, và lớp tri thức có quản trị. Điểm mới nằm ở việc ghép các phần này với các bất biến được thực thi, không ở từng mảnh riêng.



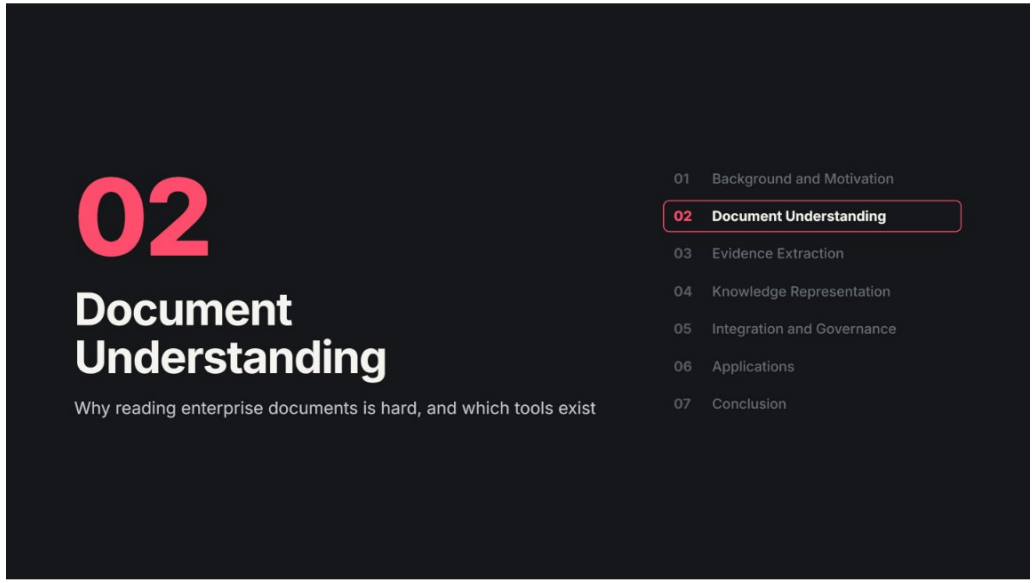
01 · BACKGROUND AND MOTIVATION

Positioning against common approaches

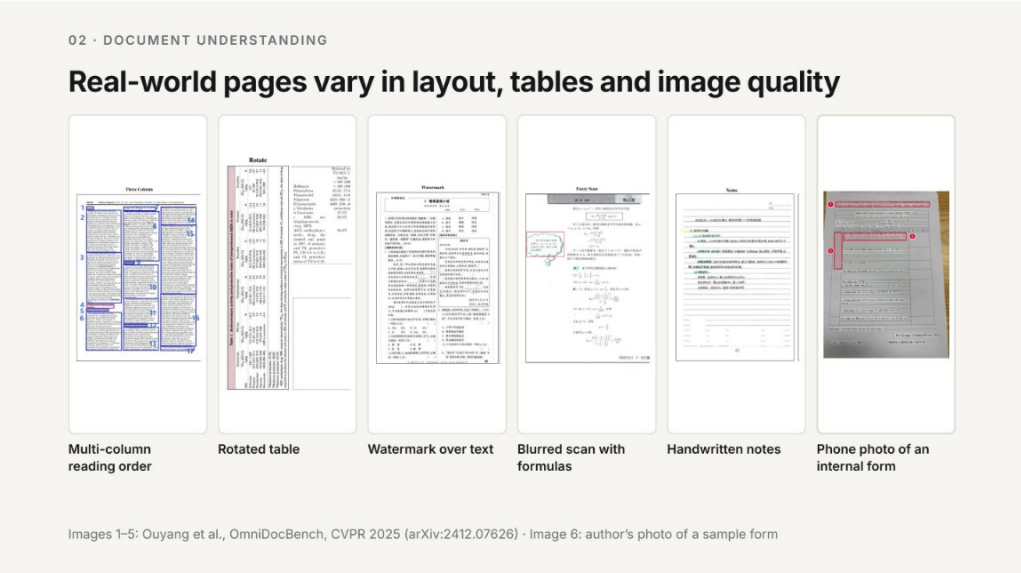
	UNIT OF KNOWLEDGE	LINK TO SOURCE	WHO DECIDES	CHANGE OVER TIME
Vector RAG	text chunk	chunk citation	the model, at answer time	re-index
GraphRAG	LLM-extracted graph, summaries	source text unit	the model, at indexing	re-index
Document parsers	document elements	page and box	not addressed	not addressed
This work	**approved, typed fact**	**page, box and version**	**a reviewer, enforced**	**immutable versions, as-of queries**

GraphRAG: Edge et al., arXiv:2404.16130 (2024) · Document parsers, e.g. Docling: Auer et al., arXiv:2408.09869 (2024) · author's comparison

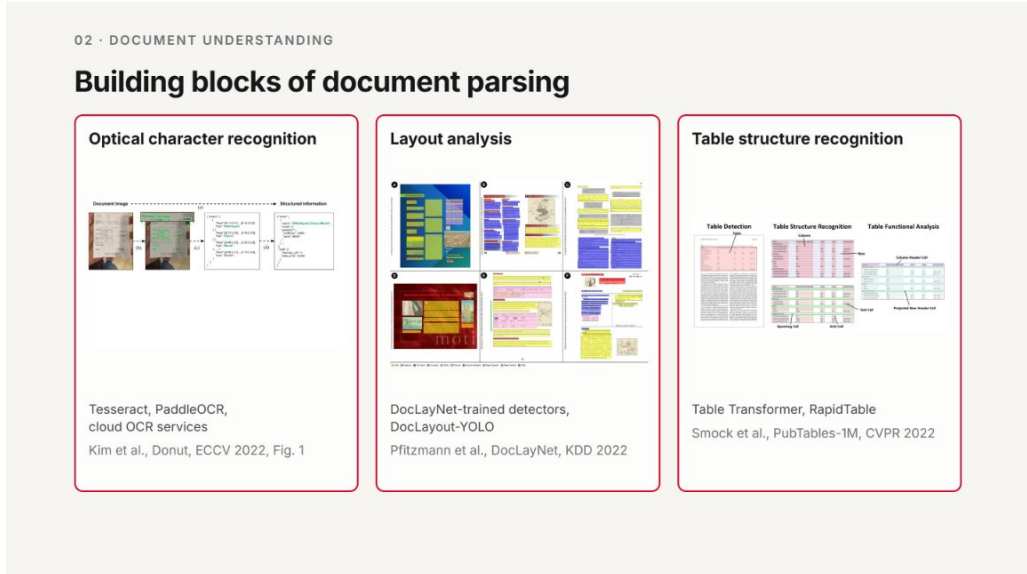
Định vị so với các cách phổ biến, không đối đầu mà bổ sung. RAG vector lưu đoạn văn, dẫn nguồn ở mức đoạn, và mô hình tự quyết lúc trả lời. GraphRAG của Microsoft dùng LLM dựng đồ thị và bản tóm tắt từ văn bản, nguồn là đơn vị văn bản, mô hình quyết lúc lập chỉ mục. Bộ đọc tài liệu như Docling giữ trang và khung, nhưng không xử lý ý nghĩa hay duyệt. Đề tài của em: đơn vị là fact có kiểu đã duyệt, truy tới trang, khung và phiên bản, người duyệt quyết định và được thực thi, thay đổi bằng phiên bản bất biến và hỏi được theo thời điểm.



Phần 2: vì sao đọc tài liệu doanh nghiệp là bài toán khó, và các công cụ hiện có.



Một slide cho tất cả cái khó. Năm ảnh đầu lấy từ OmniDocBench, bộ chuẩn CVPR 2025 gồm khoảng 1.000 trang thuộc 9 loại tài liệu, gắn 19 thuộc tính trang vì độ chính xác của bộ đọc thay đổi theo từng thuộc tính: thứ tự đọc nhiều cột, bảng xoay, bảng không đường kẻ, bản scan mờ, chữ viết tay. Ảnh cuối là biểu mẫu nội bộ chụp bằng điện thoại: nghiêng, chữ nhỏ, ô gộp. Đọc sai ở đây thì mọi bước sau đều sai.

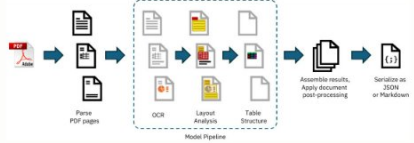


Ba khối xây dựng của việc đọc tài liệu. OCR phát hiện vùng chữ rồi nhận dạng ký tự; công cụ phổ biến là Tesseract, PaddleOCR. Phân tích bố cục gán nhãn vùng: đoạn văn, bảng, hình, tiêu đề; DocLayNet là bộ dữ liệu chuẩn. Nhận dạng cấu trúc bảng khôi phục hàng, cột, ô gộp; PubTables-1M và Table Transformer là công trình tiêu biểu. Ô bảng là đơn vị mà mỗi giá trị phải được neo vào.

02 · DOCUMENT UNDERSTANDING

Parsing approaches: modular pipelines and end-to-end models

Modular pipeline

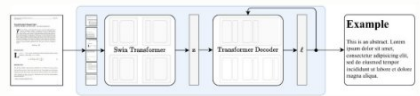


Examples: Docling, MinerU, Marker

+ each stage can be inspected, measured and replaced

− errors propagate from one stage to the next

End-to-end vision-language model



Examples: Donut, Nougat, GOT-OCR 2.0, Qwen2-VL, GPT-4o

+ fewer hand-built stages; adapts to unusual layouts

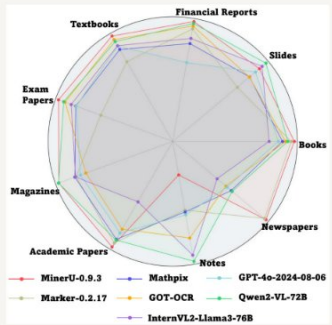
− compute-heavy; can hallucinate or repeat text

Figures: Auer et al., Docling Technical Report, arXiv:2408.09869 · Blecher et al., Nougat, ICLR 2024 (arXiv:2308.13418)

Hai họ cách tiếp cận. Pipeline ghép các mô hình chuyên biệt: OCR, bố cục, bảng; ưu điểm là kiểm tra và thay được từng bước, nhược điểm là lỗi lan từ bước này sang bước sau. Mô hình thị giác ngôn ngữ đầu cuối đọc thẳng ảnh trang ra văn bản có cấu trúc; linh hoạt với bố cục lạ nhưng tốn tài nguyên, và chính bài Nougat ghi nhận hiện tượng lặp hoặc bịa chữ trên trang dài.

02 · DOCUMENT UNDERSTANDING

No single parsing approach leads on every page type



Text recognition quality, 9 page types

Pipelines lead on papers and financial reports

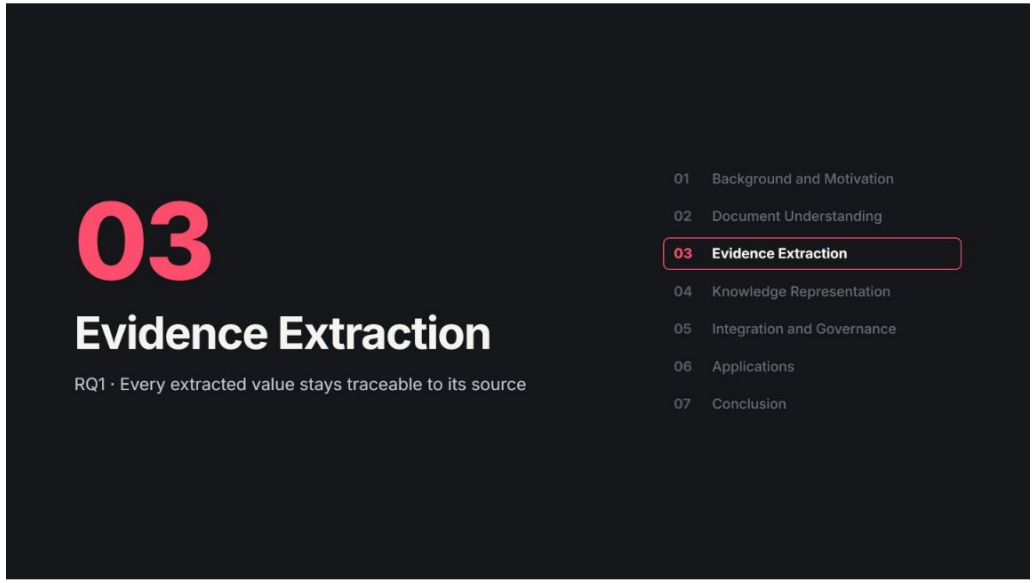
Vision-language models lead on slides, handwriting and fuzzy scans

Vision-language models fall behind on dense newspapers

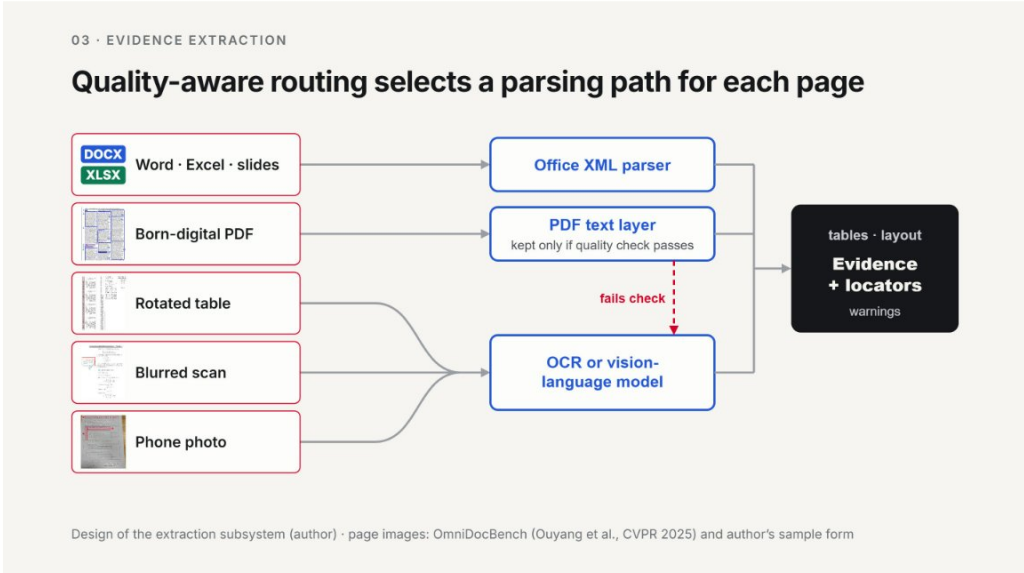
→ **Choose the path per page, not per system**

Figure and findings: Ouyang et al., OmniDocBench, CVPR 2025 (arXiv:2412.07626), Fig. 1 and Section 5

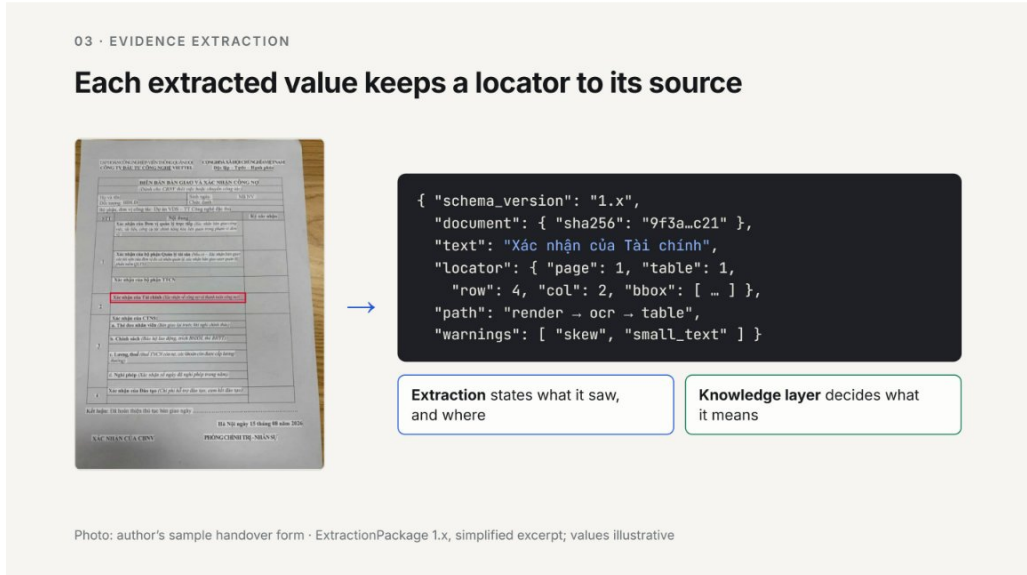
Bằng chứng khách quan từ OmniDocBench, so sánh công cụ pipeline, mô hình OCR chuyên biệt và mô hình thị giác ngôn ngữ tổng quát trên 9 loại trang. Pipeline tốt trên tài liệu phổ biến như bài báo, báo cáo tài chính. Mô hình thị giác ngôn ngữ tổng quát tốt hơn trên slide, ghi chú viết tay, bản scan mờ, nhưng yếu trên trang báo dày đặc. Không có cách nào thắng mọi loại trang, vì vậy thiết kế của em chọn đường đọc theo từng trang.



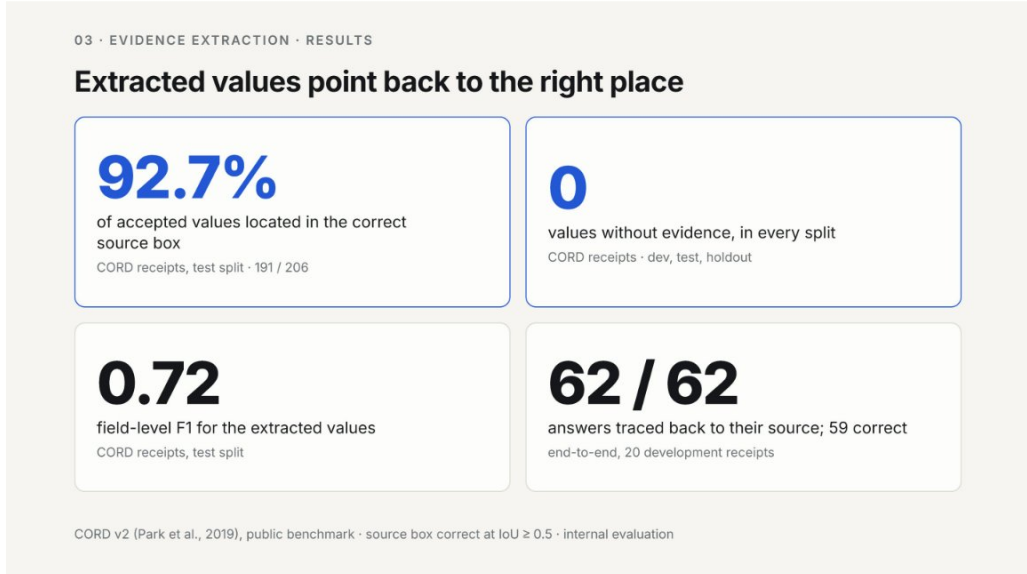
Phần 3, trả lời câu hỏi nghiên cứu thứ nhất: trích xuất mà mỗi giá trị vẫn truy được về đúng vị trí trong tài liệu gốc. Cái giá cần tránh: lỗi đọc trở thành fact sai.



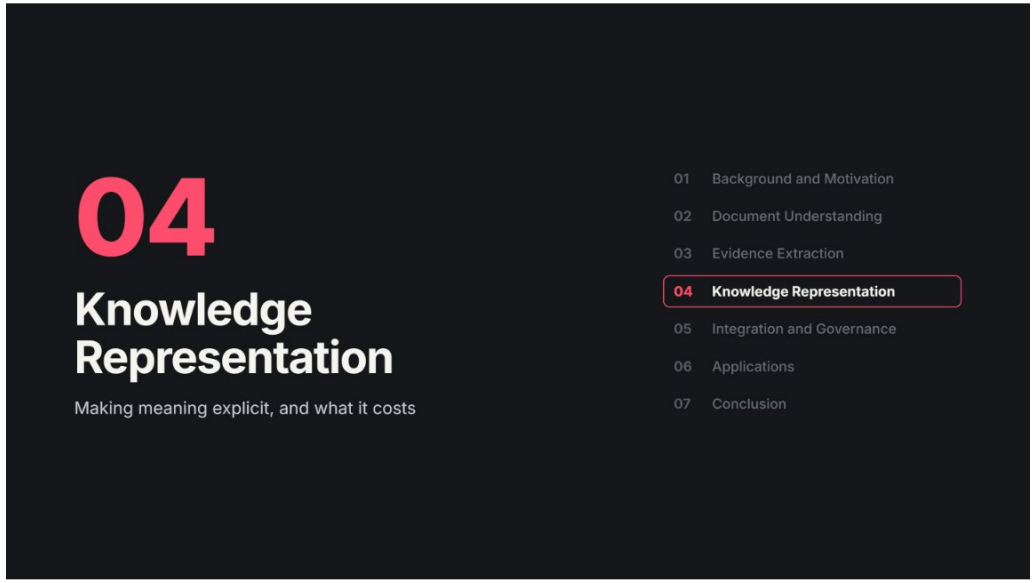
Thay vì một cách đọc cho mọi tài liệu, hệ thống kiểm tra từng file và từng trang rồi chọn đường. File Office đọc thẳng XML. PDF có lớp chữ đi đường nhanh, nhưng chỉ được giữ nếu qua kiểm tra chất lượng; trang không đạt bị chuyển sang OCR. Bảng xoay, scan mờ, ảnh chụp điện thoại đi đường OCR hoặc mô hình thị giác ngôn ngữ. Mọi đường đều qua nhận dạng bảng và bố cục, và ra cùng một dạng: bằng chứng có địa chỉ nguồn kèm cảnh báo.



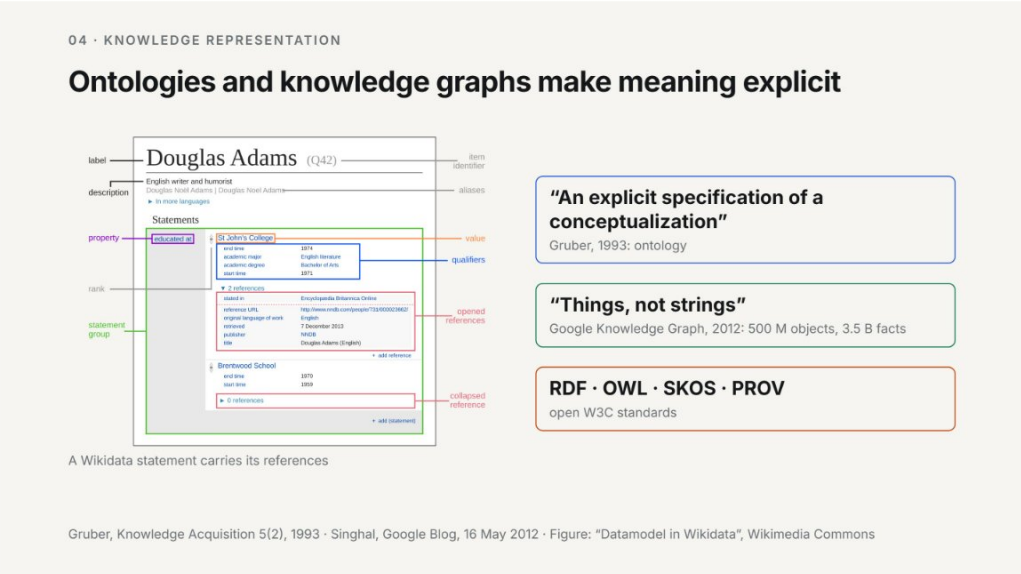
Đầu ra không phải chuỗi chữ rời rạc mà là đối tượng bằng chứng trong gói ExtractionPackage có phiên bản, kiểm bằng JSON Schema. Mỗi giá trị mang mã băm tài liệu, trang, bảng, hàng, cột, khung vị trí, đường xử lý và cảnh báo, nên người duyệt quay lại được đúng ô gốc. Hợp đồng này tách hai việc: phần trích xuất chỉ nói thấy gì và ở đâu, phần tri thức mới quyết định nghĩa là gì. Nhờ vậy thay được bộ đọc mà không đổi tri thức đã duyệt.



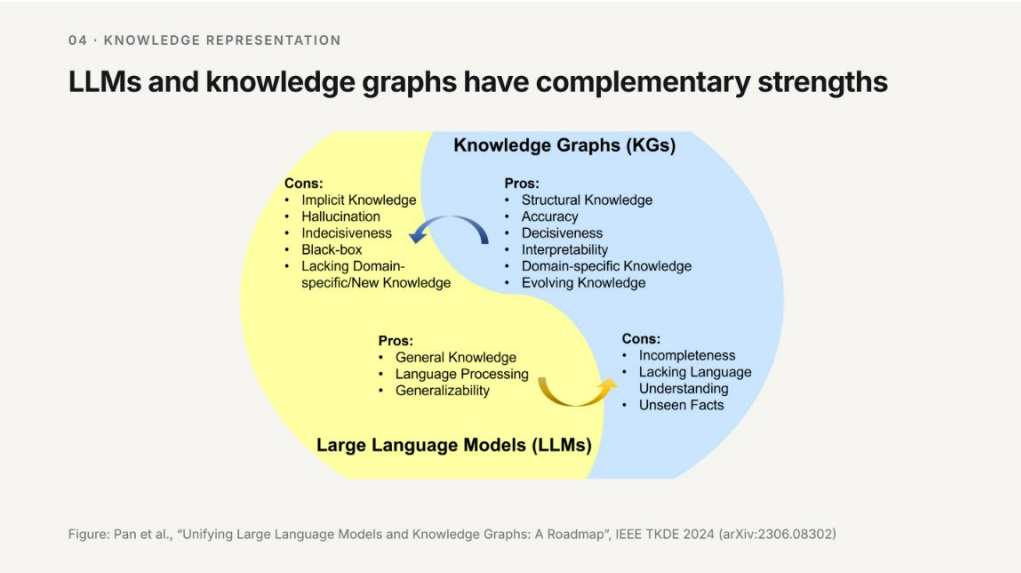
Kết quả trích xuất trên bộ chuẩn công khai CORD. Trên tập test, 92,7% giá trị hệ thống đã nhận nằm đúng khung nguồn, tức 191 trên 206, với ngưỡng IoU 0,5. Không giá trị nào thiếu bằng chứng ở mọi tập. F1 mức trường là 0,72, nghĩa là vẫn có giá trị chưa trích được. Chạy đầu cuối trên 20 hóa đơn: cả 62 câu trả lời truy được về nguồn, 59 câu đúng; truy được không có nghĩa là đúng, nên mới cần bước duyệt.



Phần 4: biểu diễn tri thức bằng ontology và đồ thị tri thức. Cái giá: mô hình hóa cả doanh nghiệp một lần thì chậm và dễ vỡ, nên em làm ontology theo từng miền.



Ontology, theo định nghĩa kinh điển của Gruber, là đặc tả tường minh của một hệ khái niệm. Đồ thị tri thức lưu các phát biểu về thực thể và quan hệ: Google gọi là "things, not strings", và khi ra mắt năm 2012 đã có 500 triệu đối tượng, 3,5 tỷ fact. Wikidata là ví dụ thực tế: mỗi phát biểu có giá trị, thuộc tính bổ sung và tham chiếu tới nguồn. Các chuẩn mở của W3C: RDF cho dữ liệu, OWL cho ontology, SKOS cho bộ từ vựng, PROV cho nguồn gốc.

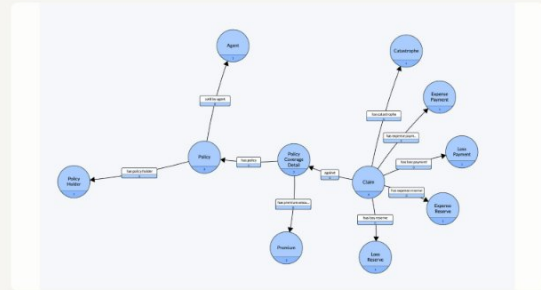


Hình này lấy nguyên từ bài tổng quan của Pan và cộng sự trên IEEE TKDE 2024. Mô hình ngôn ngữ mạnh về kiến thức chung, xử lý ngôn ngữ và khái quát hóa, nhưng là hộp đen, có thể bịa, thiếu tri thức chuyên ngành và tri thức mới. Đồ thị tri thức thì ngược lại: có cấu trúc, chính xác, giải thích được, chuyên ngành, cập nhật được; nhưng không đầy đủ và không hiểu ngôn ngữ. Hai bên bổ sung nhau, không thay thế nhau.

04 · KNOWLEDGE REPRESENTATION

Explicit semantics raised LLM accuracy on enterprise data





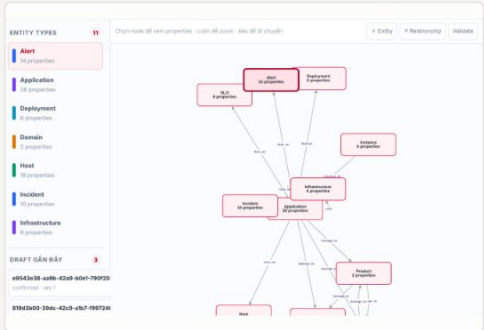
Part of the benchmark's insurance ontology

Sequeda, Allemang & Jacob, arXiv:2311.07509 (2023) · one benchmark, zero-shot GPT-4 · bars redrawn from the paper

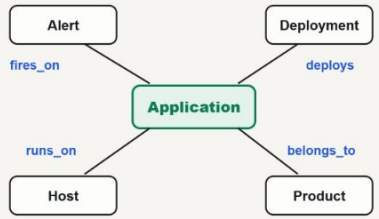
Một bằng chứng định lượng khách quan: trên một bộ chuẩn doanh nghiệp ngành bảo hiểm, GPT-4 trả lời đúng 16,7% câu hỏi nghiệp vụ khi truy vấn thẳng cơ sở dữ liệu SQL, và 54,2% khi cùng dữ liệu đó được biểu diễn qua đồ thị tri thức có ontology. Đây là một bộ chuẩn, không phải kết luận chung, nhưng cho thấy ngữ nghĩa tường minh giúp mô hình ngôn ngữ đáng kể.

04 · KNOWLEDGE REPRESENTATION

An ontology for the IT-operations domain



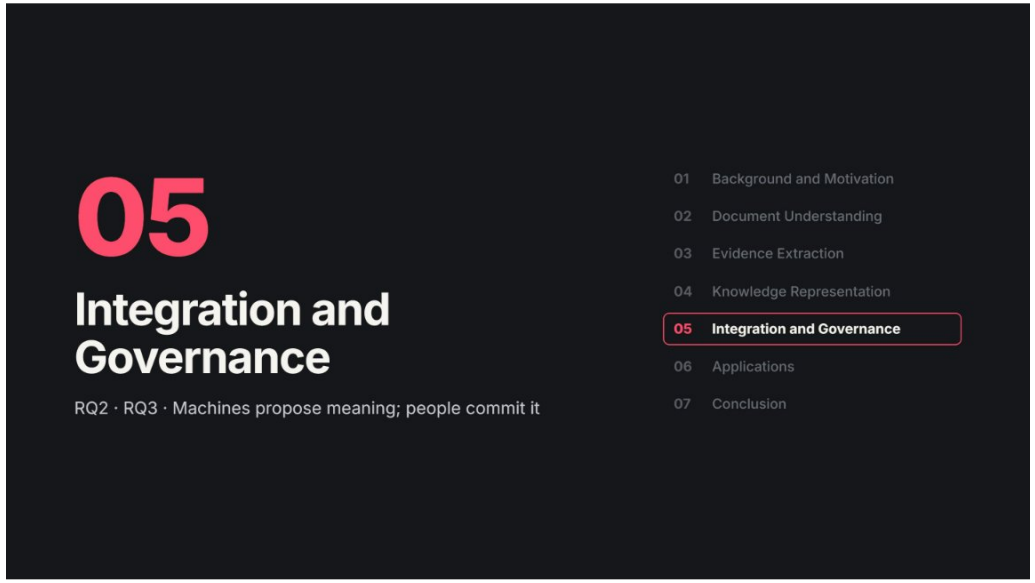
THE SLICE USED BY THE RUNNING EXAMPLE



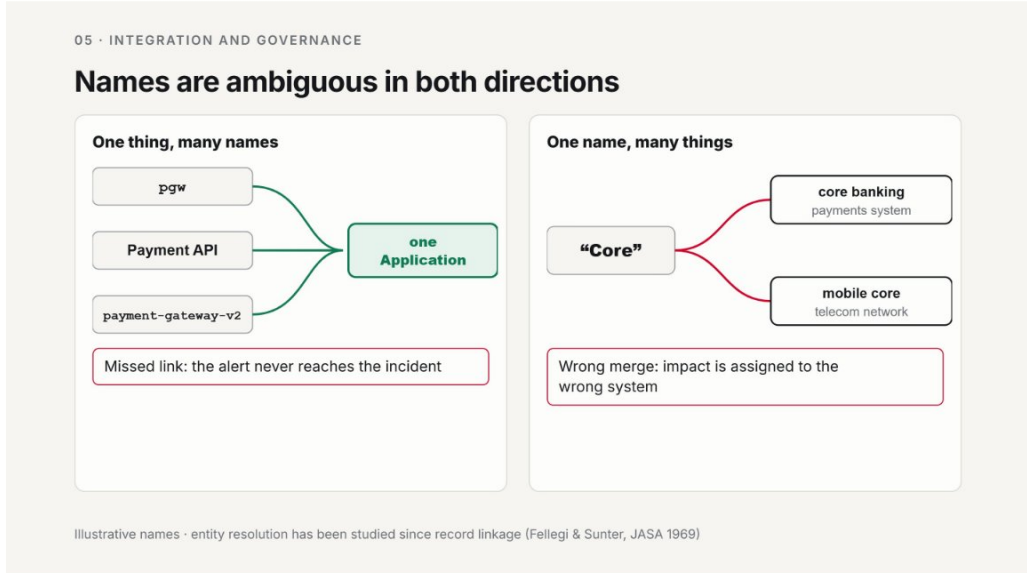
11 entity types · **8** relation types

Screenshot: Ontology Studio prototype, Ontology v1 · slice redrawn from the same schema

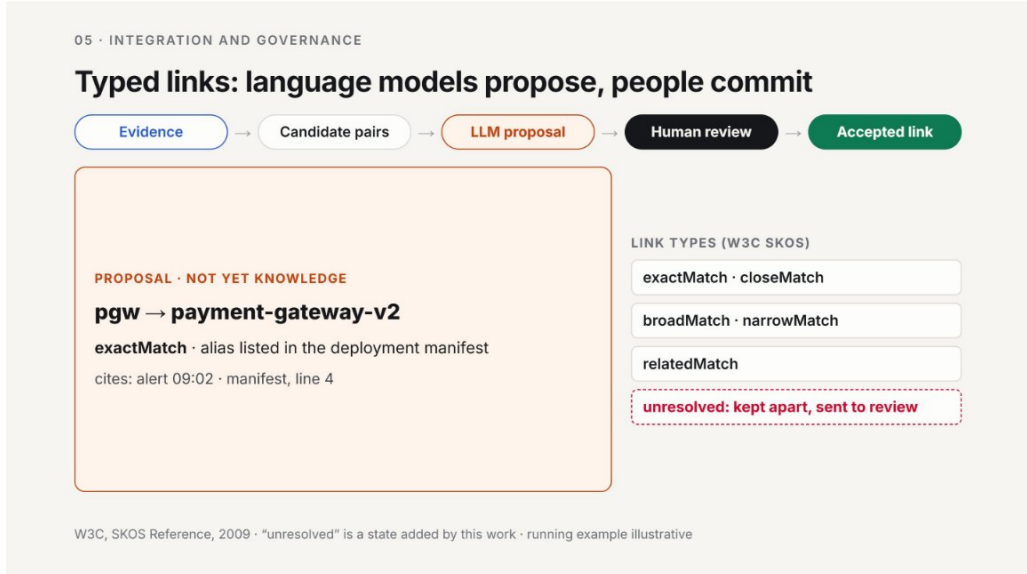
Ontology thật của miền vận hành CNTT trong Ontology Studio: 11 loại thực thể như Alert, Application, Deployment, Host, Incident, SLO, Product, và 8 loại quan hệ như fires_on, deploys, runs_on, belongs_to. Bên phải là lát cắt ví dụ xuyên suốt dùng: cảnh báo bắn vào ứng dụng, bản triển khai triển khai ứng dụng, ứng dụng chạy trên host. Ontology là tài sản có phiên bản: soạn nháp, kiểm tra tác động, rồi mới phát hành.



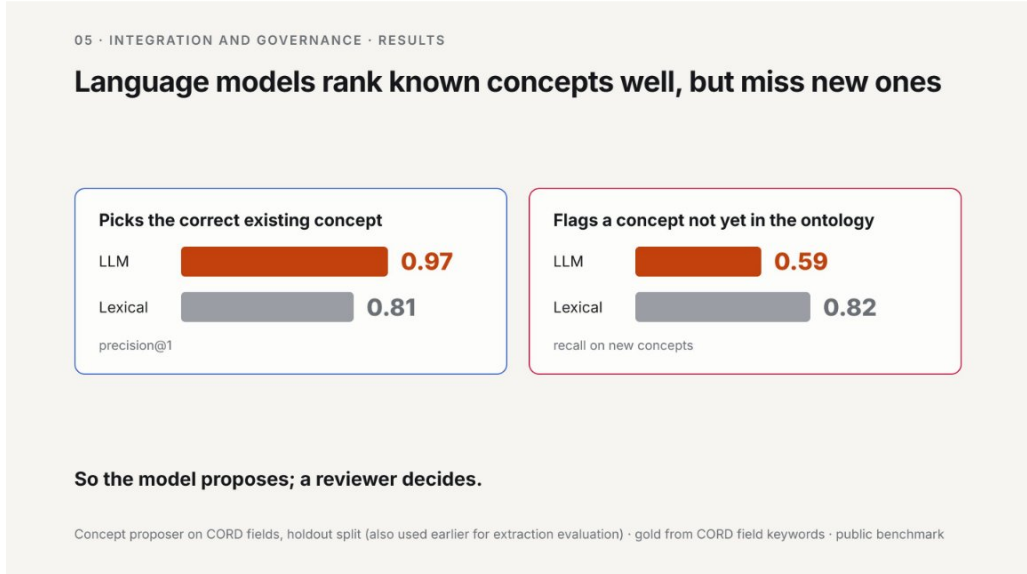
Phần 5, trả lời câu hỏi nghiên cứu thứ hai và thứ ba: nối tên gọi với ý nghĩa, và quản trị tri thức. Cái giá: tên gọi mơ hồ, công sức người duyệt, và tri thức thay đổi theo thời gian.



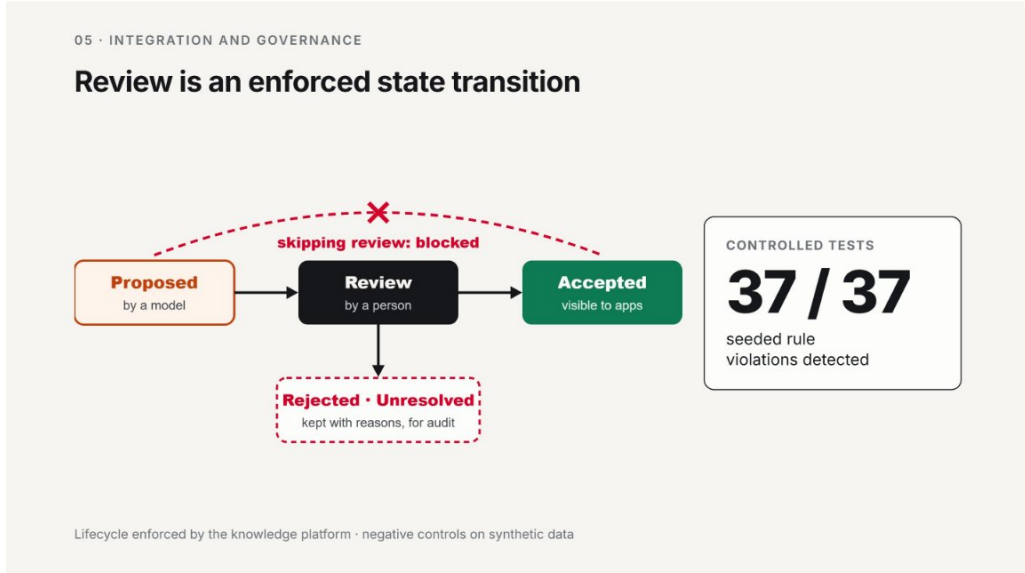
Tên gọi mơ hồ theo cả hai chiều. Một thứ nhiều tên: cảnh báo ghi pgw, ticket ghi Payment API, manifest ghi payment-gateway-v2, nhưng đều là một ứng dụng. Nếu không nối được, cảnh báo không bao giờ gặp sự cố. Một tên nhiều thứ: chữ "core" trong một tập đoàn vừa có tài chính vừa có viễn thông có thể là hệ thống core banking hoặc mạng lõi di động. Nếu gộp nhầm, phân tích tác động sẽ đổ lỗi cho sai hệ thống. So khớp chuỗi sai theo cả hai chiều.



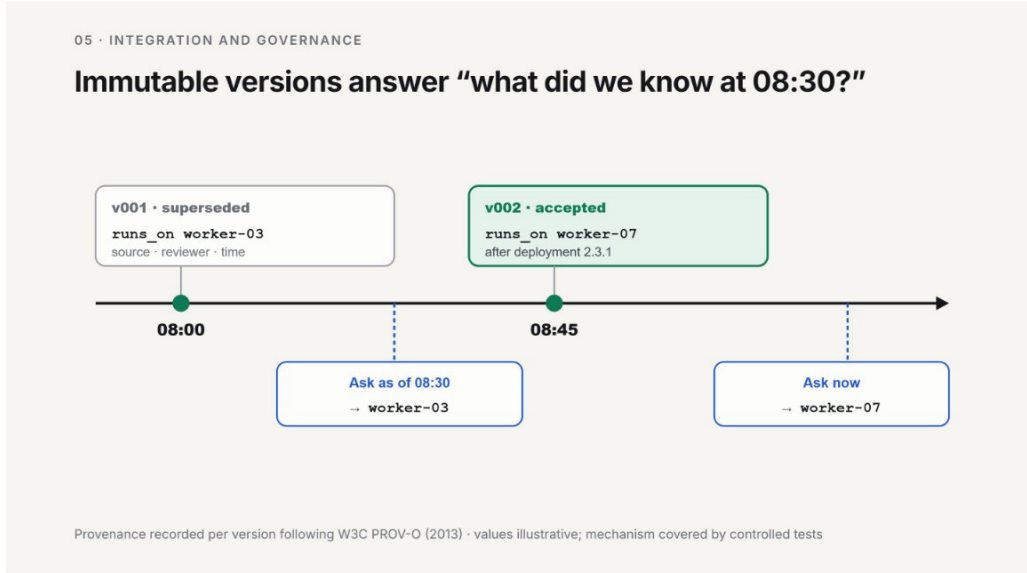
Cách nối tên với nghĩa. Từ bằng chứng, hệ thống tìm các cặp ứng viên, mô hình ngôn ngữ đề xuất kiểu liên kết, kèm lý do và nguồn trích. Ví dụ: pgw là exactMatch của payment-gateway-v2, vì manifest liệt kê pgw là bí danh. Nhưng đề xuất chưa phải tri thức: chỉ khi người duyệt chấp nhận mới thành liên kết. Kiểu liên kết theo chuẩn SKOS của W3C; em thêm trạng thái chưa xác định để cặp chưa đủ căn cứ không bị gộp ngầm.



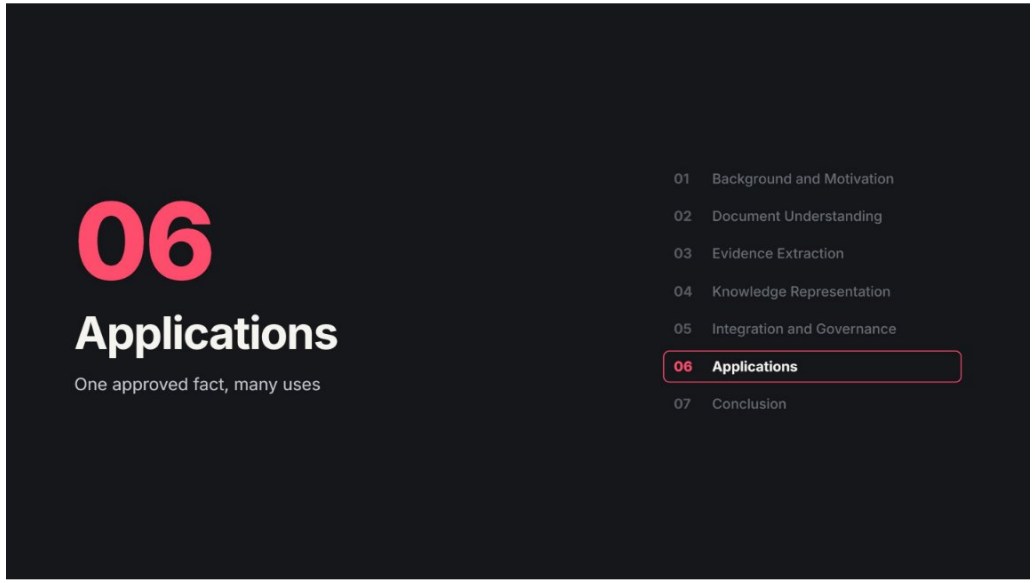
Kết quả của bước đề xuất khái niệm trên các trường của bộ CORD, tập giữ lại. Khi khái niệm đã có trong ontology, mô hình ngôn ngữ chọn đúng ở vị trí đầu 97%, so với 81% của phương pháp từ vựng. Nhưng khi khái niệm chưa có, nó chỉ nhận ra 59%, so với 82%: mô hình có xu hướng gán vào cái đã biết. Đó là lý do mô hình chỉ đề xuất và người duyệt quyết định. Lưu ý: tập giữ lại này đã dùng trước đó cho đánh giá trích xuất.



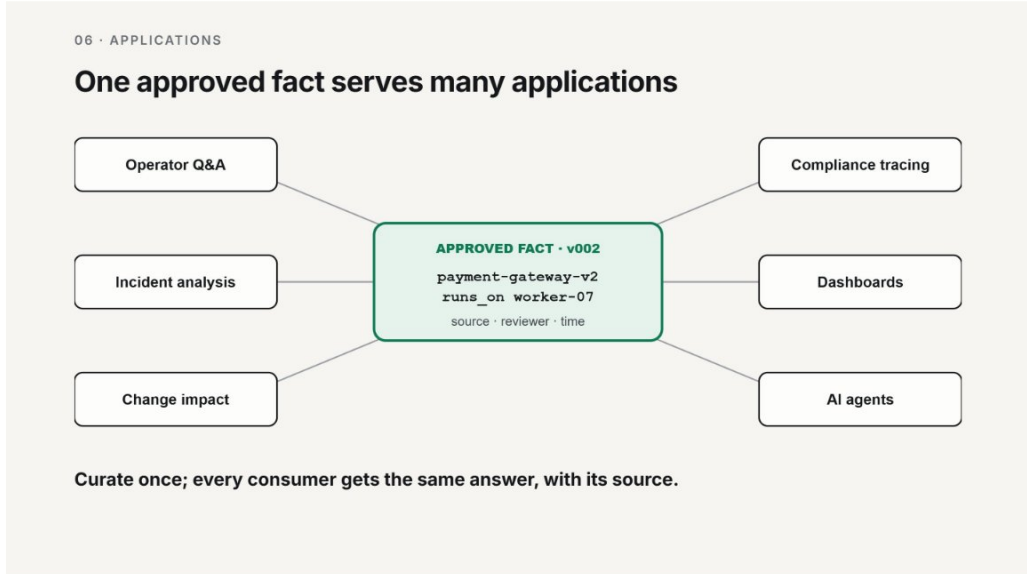
Quản trị ở đây là một bước chuyển trạng thái được thực thi, không phải văn bản chính sách. Cái do mô hình đề xuất phải qua người duyệt mới được chấp nhận và ứng dụng mới thấy. Bị loại hoặc chưa xác định thì được giữ kèm lý do để kiểm toán. Nhảy thẳng từ đề xuất sang chấp nhận bị nền tảng chặn. Kiểm chứng: 37 ca vi phạm quy tắc được cài sẵn đều bị phát hiện, trong kiểm thử có kiểm soát trên dữ liệu tổng hợp.



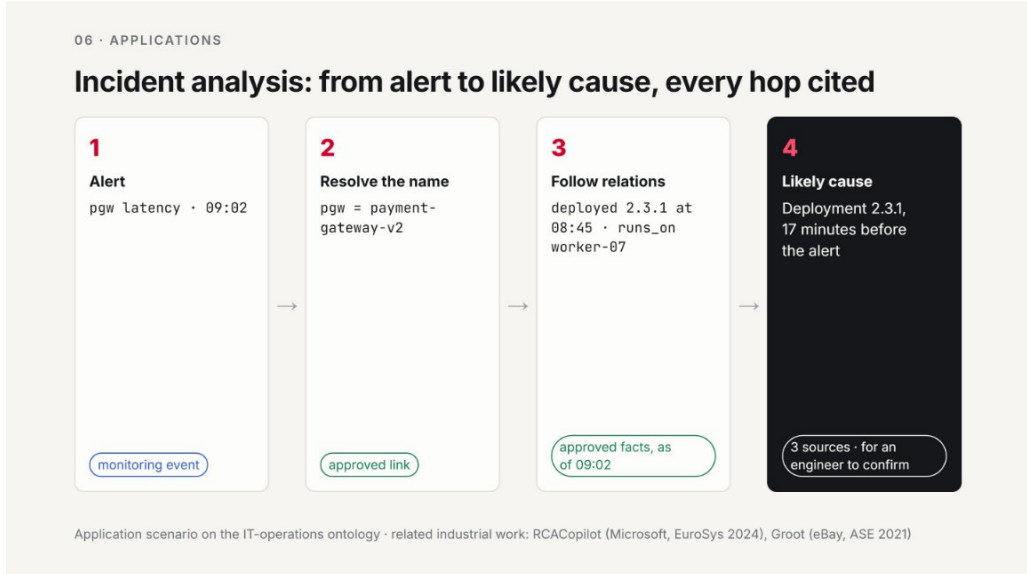
Tri thức thay đổi theo thời gian, nên không ghi đè. Lúc 8 giờ, fact payment-gateway-v2 chạy trên worker-03 là phiên bản v001. Lúc 8 giờ 45, sau bản triển khai mới, v002 ghi nhận nó chạy trên worker-07 và thay thế v001, nhưng v001 vẫn còn. Mỗi phiên bản giữ nguồn, người duyệt và thời điểm theo mô hình PROV của W3C. Nhờ vậy hỏi được theo thời điểm: lúc 8 giờ 30 hệ thống biết gì. Với điều tra sự cố, đây chính là câu hỏi then chốt.



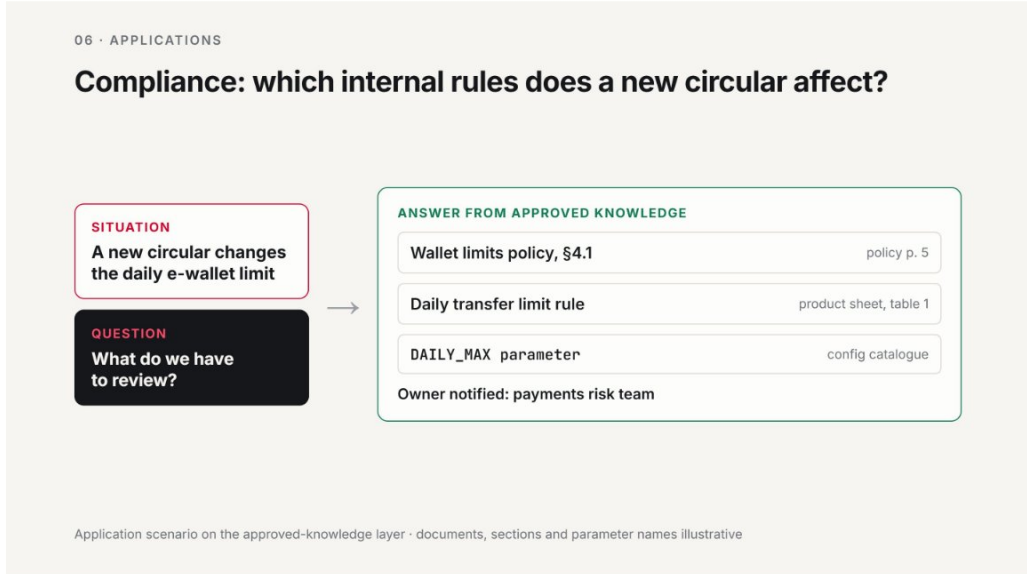
Phần 6: các ứng dụng dùng chung lớp tri thức đã duyệt.



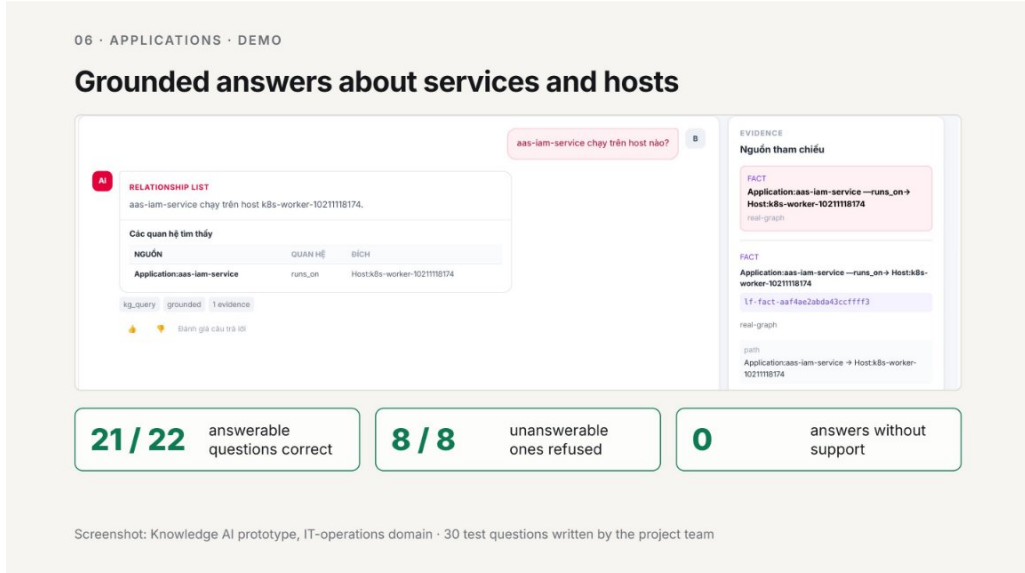
Tri thức được duyệt một lần và dùng lại nhiều nơi. Cùng một fact, ví dụ payment-gateway-v2 chạy trên worker-07, kèm nguồn, người duyệt và phiên bản, phục vụ hỏi đáp vận hành, phân tích sự cố, đánh giá tác động thay đổi, truy vết tuân thủ, dashboard và agent. Mọi bên nhận cùng một câu trả lời, cùng một nguồn; không phải mỗi ứng dụng tự đoán một kiểu.



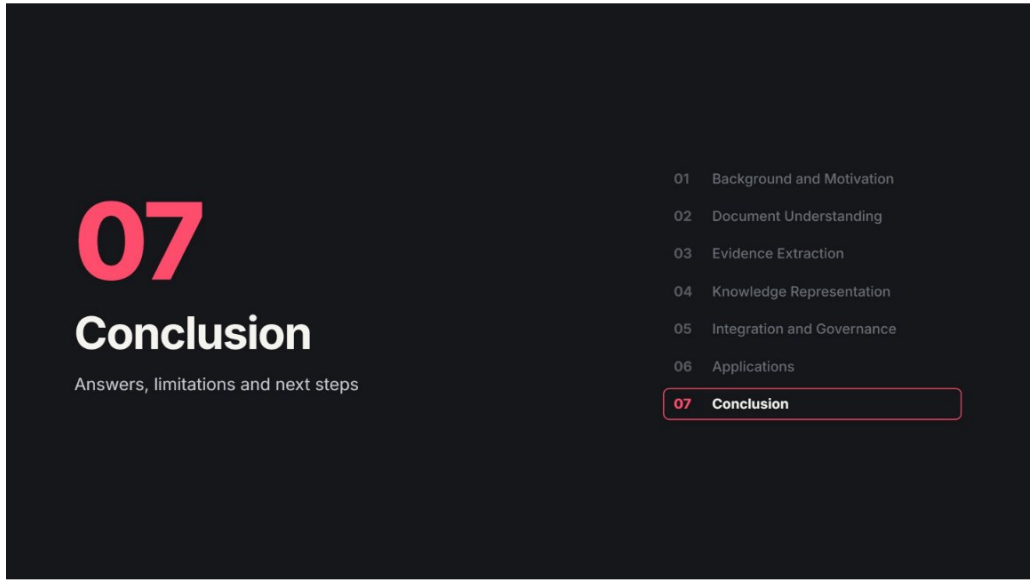
Ứng dụng gần với bài toán vận hành hằng ngày: phân tích nguyên nhân sự cố. Từ cảnh báo pgw lúc 9 giờ 02, hệ thống phân giải tên bằng liên kết đã duyệt thành payment-gateway-v2, đi theo quan hệ trên đồ thị tại đúng thời điểm đó: bản triển khai 2.3.1 lúc 8 giờ 45, chạy trên worker-07. Kết quả là một nguyên nhân khả dĩ kèm ba nguồn, để kỹ sư xác nhận. Microsoft và eBay đã dùng đồ thị và mô hình ngôn ngữ cho RCA ở quy mô công nghiệp; điểm khác ở đây là mỗi bước dựa trên tri thức có nguồn và đã duyệt.



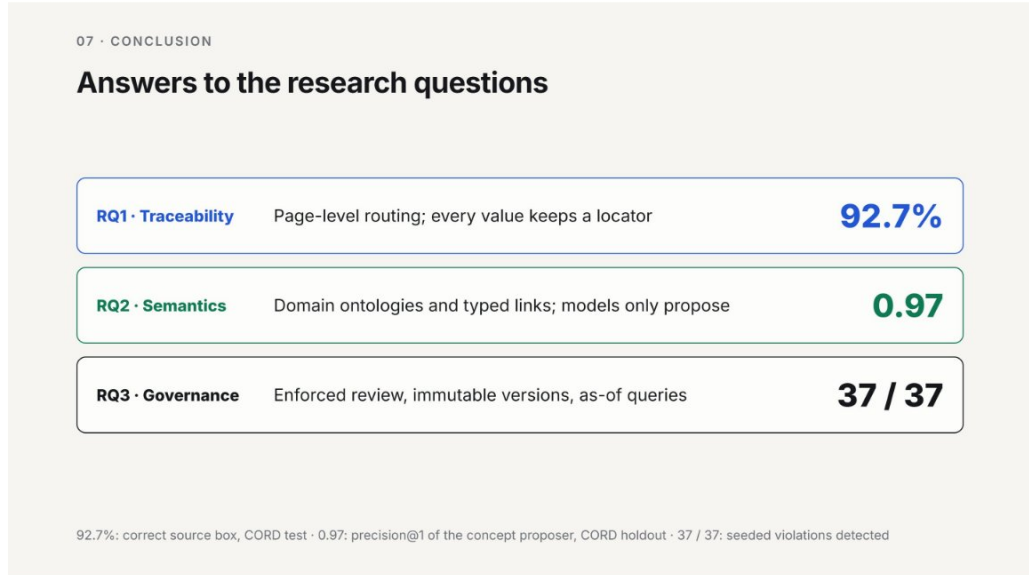
Ứng dụng thứ hai, thực tế với một công ty tài chính số. Tình huống: Ngân hàng Nhà nước ban hành thông tư mới đổi hạn mức ví. Câu hỏi của đội tuân thủ: mình phải rà lại những gì? Hệ thống trả về danh sách từ tri thức đã duyệt: điều khoản chính sách nội bộ, quy tắc sản phẩm, tham số hệ thống, mỗi mục kèm nguồn, và đơn vị phụ trách được báo. Thông tư cũ được giữ như phiên bản trước để so sánh.



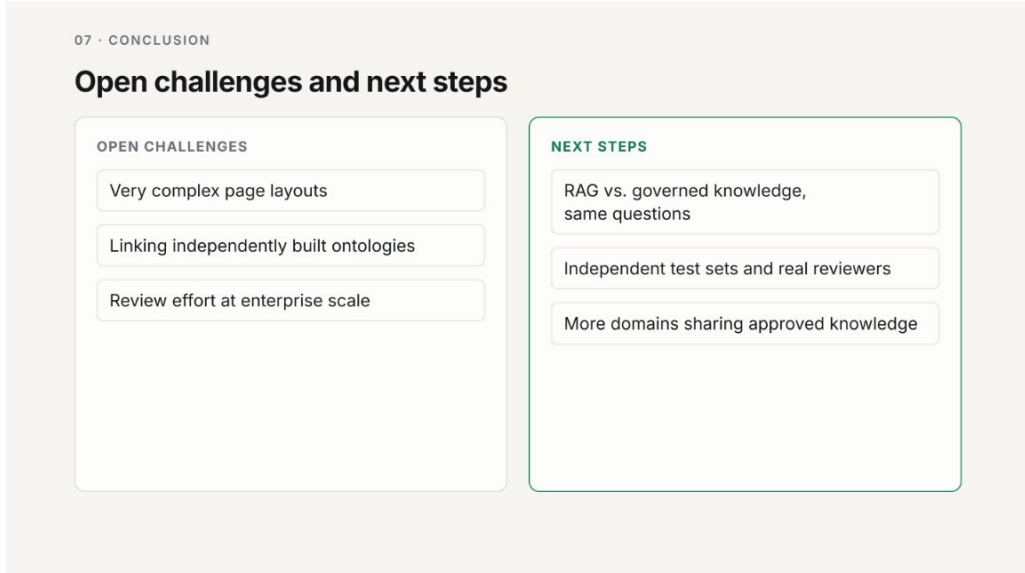
Demo trên hệ thống thật: hỏi aas-iam-service chạy trên host nào. Câu trả lời đi theo quan hệ runs_on đã duyệt; bảng bên phải là bằng chứng: fact, mã fact và đường đi trên đồ thị. Trên bộ 30 câu hỏi kiểm thử do nhóm soạn: 21 trên 22 câu có đáp án được trả lời đúng, cả 8 câu không có đáp án đều được từ chối, và không có câu trả lời nào thiếu căn cứ.



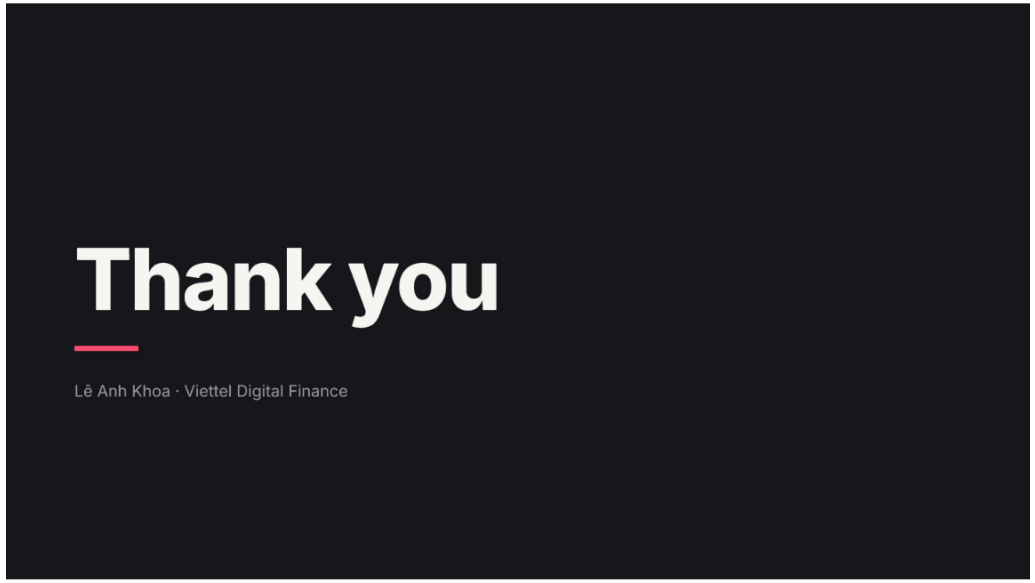
Phần 7: kết luận.



Trả lời ba câu hỏi nghiên cứu. RQ1: định tuyến theo trang, mỗi giá trị giữ địa chỉ nguồn; 92,7% giá trị đã nhận nằm đúng khung nguồn trên tập test CORD. RQ2: ontology theo miền và liên kết có kiểu; mô hình ngôn ngữ chỉ đề xuất, chọn đúng khái niệm 97% nhưng yếu với khái niệm mới, nên người duyệt quyết định. RQ3: bước duyệt được thực thi, phiên bản bất biến, hỏi được theo thời điểm; 37 trên 37 vi phạm cài sẵn bị phát hiện.



Những thách thức cần thêm thời gian: trang có bố cục rất phức tạp; liên kết giữa các ontology được xây độc lập; và công sức người duyệt khi mở rộng ra cả doanh nghiệp. Bước tiếp theo: so sánh trực tiếp RAG với tri thức đã quản trị trên cùng bộ câu hỏi; đánh giá trên tập độc lập với người duyệt thật; và mở rộng thêm miền để nhiều ứng dụng dùng chung tri thức đã duyệt.



Em xin cảm ơn hội đồng. Câu em muốn mọi người nhớ: mỗi fact đã được chấp nhận đều trả lời được ba câu hỏi: từ đâu ra, ai đã duyệt, và phiên bản nào. Em sẵn sàng nhận câu hỏi.